



UNIVERSIDAD NACIONAL DE COLOMBIA

FACULTAD DE MINAS

DEPARTAMENTO DE ENERGÍA ELÉCTRICA Y  
AUTOMÁTICA

Asignatura:  
Tópicos en Procesamiento Digital de Señales

LABORATORIO NÚMERO 2

15 de Marzo de 2024

## Uso de la correlación: Procesamiento de Señales Biomédicas

La base de datos *Pulse Transit Time PPG Dataset*, contiene datos de Fotopletismografía (PPG - Estimación de la expansión de las venas a partir de un haz de luz), Electrocardiograma (ECG - Señales eléctricas del corazón), presión, temperatura y acelerometría, tomados de 22 individuos sanos, desempeñando tres actividades físicas diferentes. A manera de ejemplo, la Figura 1 muestra la representación en el tiempo del ECG, el sensor 3 de Pletismografía, y la aceleración en el eje  $y$ , para el paciente número 10 ( $s_{10}$ ), cuando estaba corriendo. La figura muestra solo los tres primeros segundos del quinto minuto de los datos (en total la grabación abarca ocho minutos), para que se pueda distinguir el detalle de la evolución de las variables físicas.

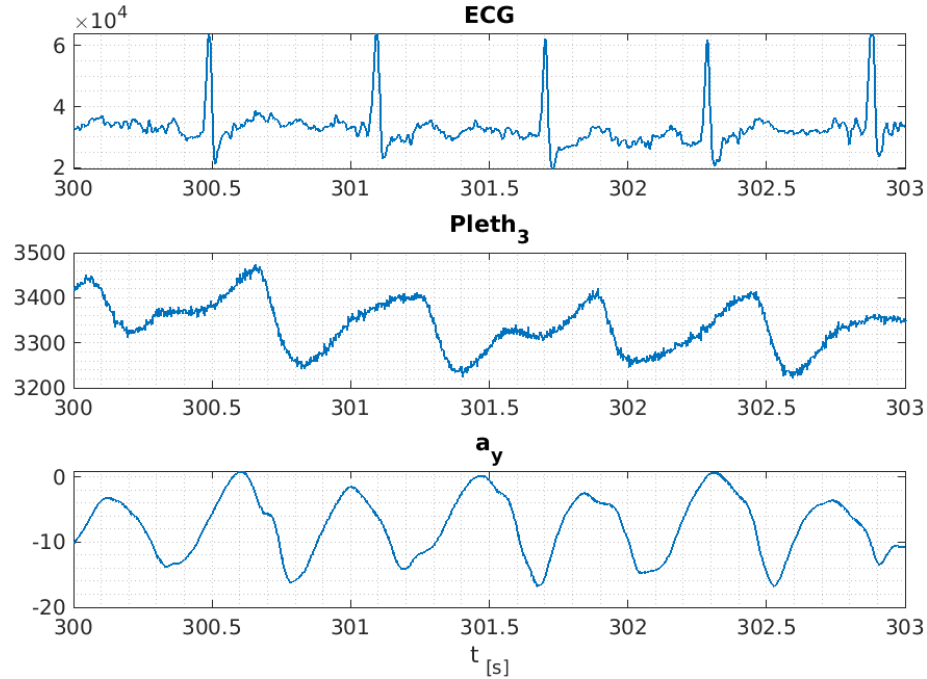


Figura 1: Tres señales biomédicas representadas en el tiempo.

Tal como muestra la figura, parece haber una relación entre las dos primeras señales (que representan la actividad cardíaca y la presión sanguínea, de forma indirecta), pero no hay mucho parecido con la tercera (que representa el movimiento vertical del paciente mientras corre). Igualmente se puede apreciar que ninguna de las tres señales en la figura parece cumplir con el criterio estricto de periodicidad, dado por la Ecuación (1).

$$x(n) = x(n \pm N) \quad (1)$$

La Ecuación (1) muestra la condición que debe cumplir cierta señal en tiempo discreto ( $x(n)$ ), para que sea considerada estrictamente periódica, con un periodo dado por el valor entero  $N$ . Como ya se dijo, ninguna de las señales de la Figura 1 parece satisfacer dicho criterio. Sin embargo, las señales pareciera que tienden a repetirse en el tiempo, por lo que se pueden considerar casi-periódicas. Este es uno de los casos en los que la *Autocorrelación* puede ayudar a estimar el periodo (intervalo de tiempo aproximado) con el que las señales tienden a repetirse.

A manera de ejemplo, la Figura 2 muestra un gráfico de la *Autocorrelación* de la señal de ECG completa (todos los ocho minutos), para las mismas condiciones enunciadas en el caso de la Figura 1<sup>1</sup>. La Autocorrelación de la Figura 2 ha sido normalizada con respecto a la energía de la señal de ECG, que de forma genérica se define para cualquier señal  $x(n)$  en tiempo discreto como:

$$E_x = \sum_{n=-\infty}^{\infty} [x(n)]^2 \quad (2)$$




Figura 2: Autocorrelación de la misma señal de ECG mostrada en la Figura 1.

El gráfico de la Figura 2 muestra un acercamiento a los alrededores del origen, nuevamente para poder visualizar mejor el detalle del comportamiento de

<sup>1</sup>La Autocorrelación funciona mejor, si se remueve la componente DC de la señal, es decir, si se le resta su valor promedio.

los datos. Como puede verse en la figura, al normalizar la Autocorrelación de la señal con la energía de la misma, ocurre un parecido máximo de 1 (100 %) en el origen, es decir, cuando el retardo relativo entre la señal de ECG y ella misma es nulo<sup>2</sup>.

Lo interesante es que existe otro pico de correlación que se destaca en un retardo diferente al nulo. La Figura 2 muestra que la señal de ECG tiende a parecerse a sí misma ( $\approx 32\%$ ) cuando el retardo es de 0,584 s. Este valor de retardo *puede interpretarse* como el periodo de la señal, lo cual significa que el estimado de pulso para el paciente en las condiciones descritas es de 102,74 pulsaciones por minuto ([ppm]).

El proceso descrito hasta ahora muestra que del volumen de *todos los datos* (ocho minutos de muestras) se obtiene un único escalar, que representa el periodo estimado con el que los datos tienden a repetirse. Si este proceso se combina con el *Método de Enventanado* visto en clase, se podría hacer una estimación en “tiempo real” de cómo va evolucionando el periodo (o la frecuencia cardíaca) a medida que transcurre el tiempo. En este punto se propone como ejercicio dicha actividad, para lo cual se sugieren los siguientes pasos:

- Seleccionar un tamaño de ventana (lapso de tiempo a considerar de los datos), adecuado para el problema.
- Escoger un solapamiento entre ventanas que permita una buena resolución en el dominio del tiempo.
- Calcular la *Autocorrelación* de cada segmento de datos.
- Establecer de forma automática el periodo estimado de cada segmento de datos, al estilo de lo mostrado en la Figura 2, y descartando la solución trivial (cuando el periodo es nulo).
- Convertir el dato de periodo en frecuencia (por ejemplo [ppm]).
- Construir un gráfico de frecuencia contra tiempo, para analizar la evolución de dicha estimación.

Aplique la metodología propuesta al menos a dos de las señales de la base de datos mencionada al principio de este punto<sup>3</sup>. Describa y analice los resultados obtenidos, y enumere las conclusiones más relevantes.

---

<sup>2</sup>Tiene sentido que la señal tenga máximo parecido con ella misma, si no ha sido desplazada.

<sup>3</sup>Para un mismo paciente.

## Correlación Cruzada, o ¿qué pasa si quiero comparar dos señales distintas?

La Figura 3 muestra el gráfico de *Correlación Cruzada* entre las señales de ECG y Pletismografía (la del tercer sensor, es decir,  $Pleth_3$ ), mostradas en la Figura 1. Se están considerando en este caso *solamente* los tres segundos de datos mostrados en la Figura 1. El gráfico de correlación ha sido obtenido teniendo en cuenta las consideraciones mencionadas en el punto anterior, a saber:

- Se debe remover el promedio (nivel DC) de las señales.
- Se debe normalizar el valor de correlación, usando como referencia (100 %) el promedio geométrico de las energías de ambas señales.
- El eje  $x$  del gráfico (retardo), ha sido escalado convenientemente por el valor del periodo de muestreo, de modo que dicho retardo aparezca en unidades de segundos. En este caso no fue necesario hacer un acercamiento, y el gráfico de correlación muestra *todos los datos*.




Figura 3: Correlación Cruzada de las señales de ECG y Pletismografía, mostradas en la Figura 1.

Como puede verse en la figura, el pico absoluto de parecido ( $\approx 25\%$ ) ya no está más en el origen (cuando no hay desfase entre las señales), y en vez de eso, parece haber un máximo parecido cuando el desfase corresponde a 0,41 s. Se deja como ejercicio para el laboratorio, el explicar el significado de dicho valor, en el sentido de si se trata de un *atraso* o *adelanto* y en referencia a qué orden de las señales.

En todo caso, ese valor de retardo puede ayudar a explicar el fenómeno físico, y a caracterizar las dinámicas del paciente, por ejemplo: ¿Con qué velocidad se propaga la señal del pulso cardíaco, hasta que se ve reflejado como un pulso en la presión sanguínea?

Para este punto se propone identificar pares de señales y hacer el cálculo de Correlación Cruzada, tanto absoluta (todo el volumen de datos), como en tiempo real (por medio del inventariado). Además se debe contestar lo siguiente:

- ¿Se evidencian cambios en el desfase para momentos diferentes de la actividad? En el caso que el desfase cambie en función del tiempo, ¿qué explicación física se podría dar a esos cambios?
- ¿Existen pares de señales “más parecidas entre sí” que otros? ¿Cómo se puede explicar este comportamiento?
- ¿Por qué la Figura 3 parece sugerir que la presión sanguínea *está adelantada* 0,41 s con respecto al ECG? ¿Tiene lógica este resultado? ¿En qué orden se asume que ocurre la causalidad entre las señales? ¿Cómo se podría corregir este fenómeno?

## Clasificación (inteligente) de patrones

La base de datos mencionada en el primer punto de esta guía proporciona información multimodal (diferentes señales, con multiplicidad de sensores), y para tres situaciones distintas: Paciente sentado, caminando o corriendo. La literatura ofrece un universo de posibles características que se pueden extraer de dichas señales, si el objetivo es clasificar automáticamente los patrones asociados a la actividad que está desarrollando el paciente (ejemplos: Valor promedio o efectivo, frecuencia, potencia, Coeficientes de Mel, Coeficientes de la STFT<sup>4</sup>, Modos de Correlación Wavelet, Cepstrum, etc).

En este punto del laboratorio se propone escoger al menos dos señales de la base de datos (presión, acelerometría, ECG, temperatura), y escoger qué características se van a extraer de dichas señales, para luego ajustar o entrenar un clasificador que sea capaz de distinguir automáticamente qué patrón de actividad está desarrollando el paciente<sup>5</sup>.

En relación al clasificador inteligente, también hay múltiples opciones, entre las que se pueden mencionar:

- **Redes neuronales artificiales:** Modelos inspirados en el funcionamiento del cerebro humano que pueden aprender de patrones complejos.

---

<sup>4</sup>Transformada de Fourier de Tiempo Corto.

<sup>5</sup>Queda claro que en este caso sí es necesario usar datos de varios (todos los) pacientes, ya que se quiere que el clasificador sea preciso.

- **Máquinas de soporte vectorial (SVM):** Utilizan un enfoque de aprendizaje supervisado para el análisis de datos y reconocimiento de patrones.
- **Clasificadores basados en reglas:** Utilizan conjuntos de reglas para asignar categorías a los datos de entrada.
- **Clasificadores bayesianos:** Se basan en el teorema de Bayes para asignar probabilidades a la pertenencia de un dato a una determinada clase.

Una vez escogido el conjunto de señales a usar, el conjunto de características correspondiente, y el tipo de clasificador automático (inteligente) que operará sobre los datos, es necesario evaluar su desempeño. Otra vez existe una plétora de métricas y herramientas disponibles, entre las que se destacan:

- **Precisión:** Mide la proporción de predicciones correctas realizadas por el clasificador.
- **Sensibilidad (*Recall*):** Indica la capacidad del clasificador para identificar correctamente los casos positivos.
- **Especificidad:** Mide la capacidad del clasificador para identificar correctamente los casos negativos.
- **Valor F1 (*F1-Score*):** Es una medida que combina la precisión y la sensibilidad en una sola métrica, útil cuando hay un desbalance entre las clases.
- **Curva ROC y área bajo la curva (AUC-ROC):** Evalúan el rendimiento del clasificador a través de la representación gráfica de la tasa de verdaderos positivos frente a la tasa de falsos positivos.
- **Matriz de confusión:** Tabla que se utiliza para describir el desempeño de un modelo de clasificación en términos de las predicciones realizadas sobre un conjunto de datos, y de cuatro categorías: Verdaderos positivos (TP), Falsos positivos (FP), Verdaderos negativos (TN) y Falsos negativos (FN).

Como ya se dijo, el propósito de este punto es implementar un clasificador automático, usando la combinación preferida de las opciones para cada etapa del proceso. El clasificador deberá ser capaz de inferir el patrón de movimiento (sentado, caminando, corriendo) a partir de los datos de entrada. Tome nota y analice los resultados obtenidos, y enumere las conclusiones más importantes de la experiencia.

## Informe

El informe del laboratorio debe contener las descripciones de las soluciones propuestas a los diferentes problemas planteados, así como los resultados obtenidos, y las comparaciones y análisis pertinentes. Deben consignarse además las

conclusiones de cada uno de los puntos desarrollados, además de las recomendaciones (si las hubiere) en referencia a dichos puntos.

Para la sustentación se permite el uso de plataformas diferentes a **Matlab** para la resolución de los problemas. Durante la sesión de sustentación cada estudiante debe explicar cómo resolvió los puntos de la presente guía, por lo que no se considera necesario consignar en el informe códigos o capturas de pantalla de los programas desarrollados.

Fecha de entrega: Martes 30 de Abril de 2024